Analyse longitudinale, travail 1

L'intérêt politique entre 1999 et 2022

Daniela Chinen Hueda

1. Introduction

Cette étude porte sur l'intérêt politique. Il s'agit de l'attention que les personnes accordent aux affaires politiques, mesurée par une auto-évaluation sur une échelle de 0 à 10. L'intérêt politique n'est pas la participation (voter, signer une pétition), mais il en est une condition importante.

La population étudiée est celle des personnes en âge de voter, soit 18 ans et plus. Avant cet âge, les actions politiques comme le vote ou la signature de pétitions sont limitées.

Deux périodes sont comparées : 1999-2007 et 2008-2022. La date de 2008 correspond au début de la crise économique.

Question de recherche. L'intérêt politique est-il différent entre 1999-2007 et 2008-2022 ? Que peut-on dire du rôle possible de la crise de 2008 ?

L'enjeu est de savoir si l'intérêt des citoyens pour la politique évolue en période de crise économique. Les résultats donnent des indices sur le lien entre conditions économiques et engagement civique. Ils décrivent des associations. Ils ne permettent pas à eux seuls d'établir une cause.

Mahéo, Dejaeghere et Stolle (2012) étudient la non-participation politique des jeunes. Ils montrent que ce groupe n'est pas homogène. Ils mobilisent le genre, le statut socio-économique, la citoyenneté, la confiance dans les institutions et l'intérêt politique. Ces variables guident le choix des variables de ce travail.

2. Données et variables

Les données forment un panel : les mêmes personnes sont interrogées plusieurs fois. Le modèle nul utilise 189 919 observations pour 29 633 personnes. Les modèles avec covariables utilisent les observations complètes : 140 196 observations pour 25 016 personnes.

Variable	Type	Rôle dans l'analyse
Intérêt politique	Dépendante (0 à 10)	Variable à expliquer
Âge	Varie dans le temps	Effet du vieillissement et différences entre âges
Revenu personnel annuel	Varie dans le temps	Effet des conditions économiques personnelles
Période (1999-2007 ou 2008-2022)	Varie dans le temps	Une même personne peut être observée dans les deux périodes
Position gauche-droite (0 à 10)	Varie peu	Contrôle idéologique
Années d'éducation	Varie peu	Contrôle socioculturel
Sexe	Constante	Différences entre hommes et femmes

Statistiques descriptives. Sur l'ensemble des observations disponibles :

Variable	n	Moyenne	Écart-type	Médiane	Min	Max
Âge	257 582	49,55	17,57	50	19	105
Revenu	167 097	61 729	60 187	53 500	0	5 502 500
Années d'éducation	248 588	13,49	3,18	12	0	21

- Sexe : 123 612 observations d'hommes, 133 960 de femmes et 4 d'autres genres. Ces 4 observations sont trop rares pour être interprétées.
- Période : 74 962 observations pour 1999-2007 et 168 581 pour 2008-2022.
- Position gauche-droite : toutes les valeurs de 0 à 10 sont présentes. La valeur la plus fréquente est 5, le centre de l'échelle.
- Revenu : la distribution est très asymétrique (maximum à 5,5 millions). Les coefficients du revenu sont donc très petits quand ils sont exprimés par euro.

3. Variations intra et inter individuelles

La variation intra-individuelle est le changement chez une même personne au fil du temps. La variation inter-individuelle est la différence entre personnes.

- **Âge :** varie chez chaque personne (intra), mais compare aussi des personnes d'âges différents (inter).
- **Revenu :** peut changer pour une même personne (intra) et différer entre personnes (inter).
- **Période :** une même personne peut être observée avant et après 2008. Cette variable varie donc à l'intérieur des personnes. Elle compare aussi des groupes qui ne sont pas toujours les mêmes.
- **Sexe :** constant pour chaque personne. Il compare uniquement des personnes entre elles.
- **Éducation et position gauche-droite :** varient peu dans le temps. Leur effet est surtout lu entre personnes.

Les modèles à effets fixes, between et within-between servent à séparer ces deux niveaux.

4. Modèles et résultats

4.1 Modèle nul (composantes de variance)

Variance entre individus : 6,453 (écart-type 2,540). Variance résiduelle, à l'intérieur des individus : 1,857 (écart-type 1,363). Intercept : 5,237 (erreur standard 0,016), soit un intérêt moyen proche du milieu de l'échelle.

ICC = 6,453 / (6,453 + 1,857) = 0,777. Environ 78 % de la variance de l'intérêt politique se situe entre les individus. Environ 22 % se situe à l'intérieur des individus, d'une année à l'autre. Un modèle multiniveau est donc justifié.

4.2 Modèle à intercept aléatoire avec covariables

Ce modèle ajoute les covariables et garde un intercept propre à chaque personne. Il mélange effets intra et inter. Il donne une vue d'ensemble, mais il ne les sépare pas.

Variable	Coefficient (erreur standard)	Lecture
Intercept	4,149 (0,056)	Intérêt moyen de la situation de référence
Femme (réf. : homme)	-0,905 (0,030)***	Intérêt plus faible chez les femmes
Période 2008-2022 (réf. : 1999-2007)	-0,242 (0,011)***	Intérêt plus faible après 2008
Âge (par année)	0,020 (0,001)***	Intérêt plus élevé aux âges plus avancés
Revenu (par euro)	0,000 (0,000), non significatif	Pas d'effet détecté
Position gauche-droite (par point)	0,012 (0,003)***	Léger, voir 4.3
Années d'éducation	0,075 (0,003)***	Intérêt plus élevé avec plus d'éducation

**** p < 0,001. Les 4 observations d'autres genres sont dans le modèle mais ne sont pas interprétées.*

Variance. La variance entre individus passe de 6,453 à 4,833 et la variance résiduelle de 1,857 à 1,653. L'ICC conditionnel est de 4,833 / (4,833 + 1,653) = 0,745.

Part de variance expliquée. R^2 inter = (6,453 - 4,833) / 6,453 = 0,251. R^2 intra = (1,857 - 1,653) / 1,857 = 0,110. Les covariables expliquent donc environ 25 % de la variance entre individus et 11 % de la variance à l'intérieur des individus. Ces valeurs sont indicatives : le modèle nul et le modèle complet ne portent pas sur le même échantillon (189 919 contre 140 196 observations).

La période et la crise de 2008. L'intérêt politique est plus faible de 0,24 point après 2008. C'est une association entre la période et l'intérêt. Elle est compatible avec un effet de la crise, mais d'autres événements ou un changement de composition de l'échantillon peuvent aussi jouer. Le revenu personnel n'est pas significatif : il ne semble pas expliquer cette différence.

4.3 Comparaison : régression simple, effets fixes, between et within-between

Quatre approches sont comparées. Les effets fixes comparent une personne à elle-même au fil du temps. Le modèle between compare des moyennes de personnes. Le within-between estime les deux effets en même temps, avec une moyenne de la personne (inter) et un écart à cette moyenne (intra).

Variable	Within-between	Régression simple	Effets fixes	Between
Femme	-0,804***	-0,771***	0,194 (ns)	-0,816***
Période 2008-2022	-0,051*	-0,447***	-0,046**	-0,334***
Âge (effet total)		0,036***	0,003**	0,031***
Âge, moyenne de la personne	0,032***			
Âge, écart à la moyenne	0,003 (ns)			

Variable	Within-between	Régression simple	Effets fixes	Between
Position (effet total)		-0,078***	0,030***	-0,067***
Position, moyenne de la personne	-0,157***			
Position, écart à la moyenne	-0,004 (ns)			
Années d'éducation	non incluse	0,151***	-0,001 (ns)	0,184***
Observations	39 520	140 196	140 196	25 016 personnes
R^2		0,130	0,001	0,147

** p < 0,05 ; ** p < 0,01 ; *** p < 0,001 ; ns : non significatif. Les coefficients du revenu sont très proches de zéro par euro et ne sont pas détaillés.*

Sexe. L'écart entre femmes et hommes est stable, autour de -0,8 point, dans les trois modèles qui l'estiment. Dans le modèle à effets fixes, le sexe ne devrait pas pouvoir être estimé, car il est constant. Un coefficient apparaît probablement parce que le sexe est codé différemment d'une vague à l'autre pour quelques personnes (à vérifier). Ce coefficient n'est pas interprété.

Période. Le coefficient est négatif dans tous les modèles. Dans le modèle à effets fixes, il est de -0,046 : pour une même personne, l'intérêt est un peu plus bas après 2008. Les écarts sont plus grands dans la régression simple (-0,447) et le modèle between (-0,334). Les personnes observées avant et après 2008 ne sont pas exactement les mêmes, et ces modèles mélangent ces différences avec l'effet de la période.

Âge. L'effet de l'âge se lit surtout entre les personnes : les personnes plus âgées sont plus intéressées (0,032 par année). Pour une même personne, le vieillissement change très peu l'intérêt (0,003 par année, soit environ 0,03 point par décennie). Les différences observées entre âges reflètent donc surtout des différences entre personnes, et non un gain d'intérêt avec le temps.

Éducation. Elle est associée à un intérêt plus élevé entre les personnes (0,184 dans le modèle between). Chez une même personne, l'effet est nul, car l'éducation varie peu.

Position gauche-droite. L'échelle va de la gauche à la droite : un coefficient positif signifie une position plus à droite, pas une position plus affirmée. Entre personnes, être plus à droite est associé à un intérêt plus faible (-0,067 et -0,157 selon le modèle). Chez une même personne, le signe est positif dans les effets fixes (0,030) mais nul dans le within-between (-0,004). Ces résultats sont à lire avec prudence, car ils viennent d'échantillons différents.

Revenu. Les coefficients sont minuscules par euro. Dans le within-between, la moyenne du revenu a un coefficient de 0,000004152 par euro, soit environ 0,04 point pour 10 000 euros. L'effet est positif mais très faible.

Échantillon du within-between. Ce modèle utilise 39 520 observations pour 7 491 personnes, à cause des valeurs manquantes sur certaines variables. Il n'est pas directement comparable aux autres modèles.

4.4 Courbe de croissance

Ce modèle laisse l'intercept et la pente de l'âge varier d'une personne à l'autre. Il compare deux versions : avec une pente aléatoire et avec un intercept aléatoire seul.

- Effet moyen de l'âge entre personnes : 0,031 par année (très significatif).
- Effet moyen de l'âge à l'intérieur d'une personne : -0,0002, donc nul en moyenne.
- Variance de l'intercept : 6,217 (écart-type 2,493). Les niveaux de départ diffèrent beaucoup entre personnes.
- Variance de la pente : 0,0093 (écart-type 0,096 par année). Elle semble petite, mais elle est grande par rapport à l'effet moyen, qui est proche de zéro. Pour certaines personnes l'intérêt monte avec l'âge, pour d'autres il baisse.
- Le test de comparaison des deux versions est très significatif (khi-deux = 7 951,9 pour 2 degrés de liberté, $p < 0,001$). La pente aléatoire améliore l'ajustement (AIC de 727 821 contre 735 769).

Le modèle a affiché un avertissement de convergence (âge non recentré). Les valeurs sont donc à lire comme des ordres de grandeur. Le script du dépôt GitHub recentre et réduit l'âge pour corriger ce point.

5. Conclusion

- La plus grande part de la variation de l'intérêt politique se situe entre les individus (ICC de 0,78).
- Les femmes sont moins intéressées par la politique que les hommes (environ -0,8 point). Un niveau d'éducation plus élevé est associé à un intérêt plus élevé.
- L'intérêt est plus faible après 2008, dans tous les modèles. L'écart va de -0,05 à -0,45 point selon le modèle (-0,24 dans le modèle principal). C'est une association, compatible avec un effet de la crise mais qui ne le démontre pas.
- Le revenu personnel ne semble pas expliquer cette différence.
- Les différences d'âge viennent surtout de différences entre personnes. Pour une même personne, l'intérêt change peu avec l'âge, mais les trajectoires individuelles diffèrent.

Ce travail montre l'intérêt de séparer les effets intra et inter individuels. Selon le modèle, une même variable peut prendre des valeurs et des signes différents.

6. Pistes pour prolonger le travail

- Estimer tous les modèles sur un même échantillon pour comparer directement les résultats et les R^2.
- Passer le revenu en logarithme et recentrer l'âge pour des modèles plus stables.
- Construire une mesure de position politique affirmée (distance au centre de l'échelle).
- Ajouter des variables liées à la crise (chômage, situation économique du ménage) pour se rapprocher d'un test du mécanisme.
- Vérifier le codage du sexe dans les vagues successives.

Le code R correspondant, avec un jeu de données simulé, est disponible dans le dépôt GitHub de ce projet.

Bibliographie

Mahéo, Valérie-Anne, Yves Dejaeghere et Dietlind Stolle. « La non-participation politique des jeunes : une étude des barrières temporaires et permanentes de l'engagement ». Revue canadienne de science politique 45, no 2 (2012) : 405-425.

Annexe : sorties R du travail original

Les captures ci-dessous montrent les sorties obtenues sur les données réelles.

```
> descriptive_stats
        vars      n     mean       sd median  trimmed      mad min     max   range  skew kurtosis
age        1 257582    49.55    17.57     50    49.28    19.27  19     105      86  0.10    -0.82
income     2 167097 61729.27 60187.36  53500 55157.27 39140.64   0 5502500 5502500 17.89  1028.74
eduyear    3 248588    13.49     3.18     12    13.36     2.97   0      21      21  0.48    -0.58
            se
age       0.03
income  147.24
eduyear   0.01
> sex_df
    Sex Frequency
1   man    123612
2 woman    133960
3 other         4
> polpos_df
   Polpos Frequency
1       0      7712
2       1      2604
3       2     11040
4       3     19406
5       4     22438
6       5     51175
7       6     17295
8       7     17207
9       8     11259
10      9      1968
11     10      4638
> cohort_df
     Cohort Frequency
1 1999-2007     74962
2 2008-2022    168581
>
```

Figure 1. Statistiques descriptives

```
> summary(m1)
Linear mixed model fit by REML. t-tests use Satterthwaite's method ['lmerModLmerTest']
Formula: polint ~ 1 + (1 | IDPERS)
   Data: data

REML criterion at convergence: 737071

Scaled residuals:
    Min      1Q  Median      3Q     Max
-6.3843 -0.4834  0.0194  0.5018  6.7185

Random effects:
 Groups   Name        Variance Std.Dev.
 IDPERS   (Intercept) 6.453    2.540
 Residual             1.857    1.363
Number of obs: 189919, groups:  IDPERS, 29633

Fixed effects:
             Estimate Std. Error        df t value Pr(>|t|)
(Intercept) 5.237e+00  1.552e-02 2.913e+04   337.5   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
>
```

Figure 2. Modèle nul

```
> m2 <- lmer(polint ~ 1
+            + sex
+            + cohort
+            + age
+            + income
+            + polpos
+            + eduyear +  (1 | IDPERS), data = data)
> summary(m2)
Linear mixed model fit by REML. t-tests use Satterthwaite's method ['lmerModLmerTest']
Formula: polint ~ 1 + sex + cohort + age + income + polpos + eduyear +      (1 | IDPERS)
   Data: data

REML criterion at convergence: 529418

Scaled residuals:
    Min      1Q  Median      3Q     Max
-6.6606 -0.4860  0.0428  0.5126  5.8950

Random effects:
 Groups   Name        Variance Std.Dev.
 IDPERS   (Intercept) 4.833    2.198
 Residual             1.653    1.286
Number of obs: 140196, groups:  IDPERS, 25016

Fixed effects:
                  Estimate Std. Error         df t value Pr(>|t|)
(Intercept)      4.149e+00  5.643e-02  8.330e+04  73.535  < 2e-16 ***
sexwoman        -9.047e-01  2.994e-02  2.449e+04 -30.218  < 2e-16 ***
sexother         1.628e+00  1.698e+00  1.372e+05   0.959 0.337735
cohort2008-2022 -2.420e-01  1.149e-02  1.320e+05 -21.059  < 2e-16 ***
age              2.030e-02  6.721e-04  4.856e+04  30.211  < 2e-16 ***
income           3.605e-08  1.016e-07  1.351e+05   0.355 0.722803
polpos           1.187e-02  3.083e-03  1.400e+05   3.851 0.000118 ***
eduyear          7.519e-02  3.191e-03  9.820e+04  23.567  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Correlation of Fixed Effects:
            (Intr) sexwmn sexthr c2008- age    income polpos
sexwoman    -0.342
sexother    -0.003  0.002
ch2008-2022  0.232 -0.009 -0.001
age         -0.404 -0.025  0.002 -0.533
income       0.034  0.103  0.000 -0.029 -0.066
polpos      -0.285  0.056  0.002 -0.027 -0.048 -0.017
eduyear     -0.738  0.075  0.001 -0.082 -0.073 -0.158  0.048
```

Figure 3. Modèle à intercept aléatoire avec covariables

	WB	Reg	Fixed	Between
(Intercept)	5.475 ***	3.019 ***		2.447 ***
	(0.095)	(0.041)		(0.092)
sexwoman	-0.804 ***	-0.771 ***	0.194	-0.816 ***
	(0.053)	(0.014)	(0.389)	(0.032)
sexother	1.358	3.350	0.997	6.093
	(1.522)	(2.386)	(1.810)	(4.692)
cohort2008-2022	-0.051 *	-0.447 ***	-0.046 **	-0.334 ***
	(0.024)	(0.014)	(0.015)	(0.038)
mage	0.032 ***			
	(0.001)			
eage	0.003			
	(0.002)			
mincome	0.000 ***			
	(0.000)			
eincome	-0.000			
	(0.000)			
mpolpos	-0.157 ***			
	(0.012)			
epolpos	-0.004			
	(0.006)			
age		0.036 ***	0.003 **	0.031 ***
		(0.000)	(0.001)	(0.001)
income		0.000 ***	-0.000	0.000 ***
		(0.000)	(0.000)	(0.000)
polpos		-0.078 ***	0.030 ***	-0.067 ***
		(0.003)	(0.003)	(0.008)
eduyear		0.151 ***	-0.001	0.184 ***
		(0.002)	(0.004)	(0.005)
AIC	141001.587			
BIC	141104.602			
Log Likelihood	-70488.793			
Num. obs.	39520	140196	140196	25016
Num. groups: IDPERS	7491			
Var: IDPERS (Intercept)	4.132			
Var: Residual	1.318			
R^2		0.130	0.001	0.147
Adj. R^2		0.130	-0.216	0.147

*** p < 0.001; ** p < 0.01; * p < 0.05

>

Figure 4. Comparaison : within-between, régression simple, effets fixes, between

```
> m6 <- lmer(polint ~ 1 + mage + eage + (1 + eage | IDPERS), data = data)
> summary(m6)
Linear mixed model fit by REML. t-tests use Satterthwaite's method ['lmerModLmerTest']
Formula: polint ~ 1 + mage + eage + (1 + eage | IDPERS)
   Data: data

REML criterion at convergence: 727837

Scaled residuals:
    Min      1Q  Median      3Q     Max
-6.7160 -0.4696  0.0193  0.4898  6.6741

Random effects:
 Groups   Name        Variance Std.Dev. Corr
 IDPERS   (Intercept) 6.216581 2.49331
          eage        0.009279 0.09633  0.14
 Residual             1.658295 1.28775
Number of obs: 189919, groups:  IDPERS, 29633

Fixed effects:
             Estimate Std. Error         df t value Pr(>|t|)
(Intercept)  3.788e+00  4.262e-02  2.998e+04  88.883   <2e-16 ***
mage         3.056e-02  8.407e-04  2.953e+04  36.347   <2e-16 ***
eage        -2.069e-04  1.244e-03  7.154e+03  -0.166    0.868
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Correlation of Fixed Effects:
     (Intr) mage
mage -0.934
eage  0.013  0.014
optimizer (nloptwrap) convergence code: 0 (OK)
Model failed to converge with max|grad| = 0.0182236 (tol = 0.002, component 1)
Model is nearly unidentifiable: very large eigenvalue
 - Rescale variables?

> m7 <- lmer(polint ~ 1 + mage + eage + (1 | IDPERS), data = data)
> anova(m6, m7)
refitting model(s) with ML (instead of REML)
Data: data
Models:
m7: polint ~ 1 + mage + eage + (1 | IDPERS)
m6: polint ~ 1 + mage + eage + (1 + eage | IDPERS)
   npar    AIC    BIC  logLik deviance  Chisq Df Pr(>Chisq)
m7    5 735769 735819 -367879   735759
m6    7 727821 727892 -363903   727807 7951.9  2  < 2.2e-16 ***
```

Figure 5. Courbe de croissance et comparaison des modèles